
Módulo 2

Estadística aplicada a datos de proceso

Análisis y Pronóstico de Datos Mineros con Python

Apuntes + notebook de Google Colab

Objetivo del módulo

Describir cuantitativamente una variable, comparar condiciones de operación, evaluar relaciones y leer la incertidumbre. El módulo termina en una idea:

**las herramientas estadísticas convencionales suelen asumir
independencia entre observaciones**

describir → comparar → relacionar → inferir → cuestionar la independencia

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

La media es sensible a valores extremos. Para 10, 11, 10, 12, 57: $\bar{x} = 20$, pero casi ninguna observación está cerca de 20; la mediana es 11.

$\bar{x} \approx \text{mediana} \Rightarrow$ distribución aproximadamente simétrica

$\bar{x} > \text{mediana} \Rightarrow$ cola hacia valores altos

promedio y valor típico no siempre son lo mismo

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s = \sqrt{s^2}$$

Dos operaciones con media 1500 t/h: una entre 1450–1550, otra entre 1000–2000. El promedio no las distingue.

Comparación relativa entre escalas distintas: coeficiente de variación

$$CV = \frac{s}{\bar{x}} \quad (\text{a menudo en \%})$$

$$Q_1 = 25\%, \quad Q_2 = \text{mediana}, \quad Q_3 = 75\%$$

$$IQR = Q_3 - Q_1$$

El IQR mide la dispersión del 50 % central y es **robusto** frente a extremos (a diferencia de s).

```
q1, q3 = df["Tonelaje"].quantile([0.25, 0.75])  
iqr = q3 - q1
```

atípico no significa necesariamente incorrecto

Regla del IQR: sospechoso si

$$x < Q_1 - 1.5 IQR \quad \text{o} \quad x > Q_3 + 1.5 IQR$$

Regla de desviaciones estándar: $z_i = \frac{x_i - \bar{x}}{s}$, sospechoso si $|z| > 3$ (funciona mejor con distribuciones simétricas y sin colas largas; **no** es universal).

Comparar condiciones de operación

```
df.groupby("Turno")["Tonelaje"].agg(["mean", "median", "std", "count"])  
df.boxplot(column="Tonelaje", by="Turno")
```

Turno	Media	Mediana	Std
Día	1510	1502	85
Noche	1450	1448	130

¿cambió el tiempo o cambió la condición operacional?

Relaciones: covarianza y correlación

$$\text{Cov}(X, Y) = \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y}) \quad r = \frac{\text{Cov}(X, Y)}{s_X s_Y} \in [-1, 1]$$

- $r > 0$ asociación lineal positiva; $r < 0$ negativa; $r \approx 0$ sin relación *lineal*;
- Spearman: relación *monótona* basada en el orden.

correlación $\neq$ causalidad

secuencia: visualizar $\rightarrow$ calcular $\rightarrow$ interpretar

Dos variables que crecen durante meses pueden dar $r = 0.95$ solo por una **tendencia temporal común**.

cuando las observaciones están ordenadas en el tiempo, una correlación convencional puede ser engañosa

Todavía no hay que resolverlo; solo reconocer que existe.

De la descripción a la inferencia

Observamos una muestra $x_1, \dots, x_n$; $\bar{x}$ estima una media poblacional desconocida μ .

$$SE(\bar{x}) = \frac{s}{\sqrt{n}} \quad (\text{supone observaciones independientes})$$

Intervalo de confianza: comunica la incertidumbre del *procedimiento* de estimación, no "la media está entre estos números".

$$H_0 : \mu_{\text{día}} = \mu_{\text{noche}} \quad H_1 : \mu_{\text{día}} \neq \mu_{\text{noche}}$$

p = qué tan incompatibles son los datos con H_0 bajo el modelo. Regla usual: rechazar si $p < 0.05$.

Ojo: $p < 0.05$ **no** significa "95 % de probabilidad de que la hipótesis sea correcta".

Significancia $\neq$ relevancia operacional

Con $n = 500\,000$: Turno A $\bar{x} = 90.01$, Turno B $\bar{x} = 90.03$. Diferencia 0.02, puede salir "significativa"... ¿importa?

significativo estadísticamente $\neq$ importante operacionalmente

Y al revés: con pocos datos, una diferencia real (80 vs 90) puede no alcanzar significancia. Conclusión correcta: "no hay evidencia suficiente", no "no existe diferencia".

El supuesto clave: independencia

Un molino a 1450 t/h a las 10:00. ¿A las 10:01 es igual de probable 200, 1500 o 5000?

$$X_{t+1} \not\perp X_t$$

Muchas fórmulas convencionales suponen $x_1, \dots, x_n$ independientes. Los datos de proceso normalmente **violan** ese supuesto.

El experimento conceptual del módulo

```
| df["Tonelaje"].sample(frac=1)    # mezclar el orden al azar
```

Tras mezclar: **misma** media, mediana, desviación, histograma y cuantiles. . . pero la estructura temporal desapareció por completo.

la estadística convencional se conserva mientras toda la información temporal se pierde

Por qué la dependencia afecta la inferencia

Una variable medida cada segundo durante una hora: $n = 3600$. Si cambia lentamente, muchas mediciones consecutivas son casi iguales:

$$n_{\text{efectivo}} < n$$

Ignorarlo produce: intervalos demasiado estrechos, valores p artificialmente pequeños, sobreestimación de la precisión, conclusiones excesivamente confiadas.

Qué deberías recordar

1. Un promedio sin medida de variabilidad dice poco.
2. Media y mediana pueden contar historias distintas.
3. Los cuantiles describen sin depender de extremos.
4. Un atípico no se elimina automáticamente.
5. Comparar explícitamente turnos, campañas, tipos de mineral.
6. $\text{Corr}(X, Y) \neq$ causalidad.
7. Significancia $\neq$ relevancia operacional.
8. Toda estimación tiene incertidumbre.
9. Las herramientas tienen supuestos; el que nos importa es **independencia**.
10. Los datos de procesos suelen violarlo: $X_t \leftrightarrow X_{t-1}, X_{t-2}, \dots$

M1: *¿cómo preparo mis datos?*

M2: *¿cómo los describo e interpreto?*

→ pregunta abierta antes del receso:

¿Qué ocurre cuando los datos tienen memoria?

Ahí empieza el Módulo 3: frecuencia, tendencia, estacionalidad, ciclos, ruido, rezagos, diferencias y estadísticas móviles.