
Módulo 3

Introducción a las series temporales

Análisis y Pronóstico de Datos Mineros con Python

Apuntes + notebook de Google Colab

Objetivo del módulo

Reconocer una serie temporal, identificar sus componentes y explorar cómo cambia una variable en el tiempo.

estructura temporal → componentes → rezagos y diferencias → estadísticas móviles → descomposición

¿Qué información aparece cuando dejamos de mirar una distribución y respetamos el orden temporal?

Del dato convencional a la serie

Cada observación tiene una posición temporal: $(t_1, x_1), \dots, (t_n, x_n)$.

100, 105, 110, 115, 120 vs. 115, 100, 120, 105, 110

Misma media, misma desviación, mismo histograma. La evolución temporal solo existe en la primera.

el orden temporal contiene información que la estadística estática no conserva

Frecuencia de muestreo

La distancia entre observaciones (Δt): segundo, minuto, hora, turno, día, semana, mes.

Si un fenómeno cambia cada 10 min y medimos 1 dato/día, no lo veremos.

la frecuencia de observación limita qué comportamientos podemos detectar

La agregación (p. ej. promedio diario) puede eliminar información. Depende de la pregunta.

Componentes de una serie

$$X_t = T_t + S_t + C_t + \varepsilon_t$$

Tendencia T_t : movimiento de fondo a largo plazo (desgaste, deterioro...).

Estacionalidad S_t : patrón que se repite con periodicidad *fija* (diaria, semanal, por turno).

Ciclo C_t : oscilación recurrente sin periodo estrictamente fijo.

Ruido ε_t : lo que no atribuimos a las anteriores. No es "dato inútil".

Rezagos (lags)

$$X_{t-1}, X_{t-2}, \dots, X_{t-k} \quad (k = \text{rezago})$$

```
df["Tonelaje_lag1"] = df["Tonelaje"].shift(1)  
df["Tonelaje_lag24"] = df["Tonelaje"].shift(24)
```

El rezago permite comparar el presente con el pasado. En el Módulo 4 se cuantifica esa relación (autocorrelación).

$$\Delta X_t = X_t - X_{t-1}$$

```
| df["Cambio"] = df["Tonelaje"].diff()
```

Serie original: *¿cuál es el nivel?*

Serie diferenciada: *¿cuánto cambió?*

100, 105, 110, 115, 120 (tendencia) $\Rightarrow$ diferencias 5, 5, 5, 5. La diferenciación será clave en estacionariedad y ARIMA.

$$\bar{X}_t^{(w)} = \frac{1}{w} \sum_{i=0}^{w-1} X_{t-i}$$

```
df["media_movil"] = df["Tonelaje"].rolling(window=24).mean()  
df["std_movil"]   = df["Tonelaje"].rolling(window=24).std()
```

- media móvil → ¿cambió el nivel local?
- desviación móvil → ¿cambió la variabilidad?

la ventana se interpreta en unidades del proceso (24 h, 168 h...), no "porque se ve bonito"

Suavizado exponencial

$$S_t = \alpha X_t + (1 - \alpha)S_{t-1}, \quad 0 < \alpha < 1$$

```
| df["suave"] = df["Tonelaje"].ewm(alpha=0.2).mean()
```

$\alpha \approx 1$: responde rápido a lo nuevo. $\alpha \ll 1$: cambia lento.

suavizar revela estructura, pero también elimina la variación rápida

Media móvil: ventana explícita. Suavizado exponencial: toda la historia con pesos decrecientes.

$$X_t = T_t + S_t + R_t \quad (\text{aditiva}) \qquad X_t = T_t \cdot S_t \cdot R_t \quad (\text{multiplicativa})$$

Aditiva: amplitud estacional aproximadamente constante. Multiplicativa: crece con el nivel.

```
from statsmodels.tsa.seasonal import STL
res = STL(serie.dropna(), period=24).fit()
res.plot()
```

period = número de observaciones por periodo estacional (horario+diario $\Rightarrow$ 24).

¿Qué buscamos en la descomposición?

- Tendencia: ¿evolución lenta del nivel?
- Estacionalidad: ¿patrón recurrente?
- Residuo: ¿qué queda después de retirar esas estructuras?

una vez retirada tendencia y estacionalidad, ¿el residuo es ruido o todavía tiene estructura temporal?

Esa pregunta abre el Módulo 4.

Qué deberías recordar

1. El orden temporal contiene información.
2. La frecuencia de muestreo condiciona lo observable.
3. Componentes: tendencia, estacionalidad, ciclo, ruido.
4. Rezago: valor pasado X_{t-k} .
5. Diferencia: cambio $\Delta X_t = X_t - X_{t-1}$.
6. Estadísticas móviles: nivel y variabilidad locales.
7. Suavizar revela estructura pero pierde variación rápida.
8. Una serie se descompone (aditiva / multiplicativa).
9. El residuo no es necesariamente ruido: hay que comprobarlo.

una distribución describe qué valores aparecen; una serie temporal muestra cómo aparecen

Si X_t parece relacionado con X_{t-1} : ¿cómo se cuantifica? Si media o variabilidad cambian: ¿se puede modelar directamente?

→ Módulo 4: ACF/PACF, estacionariedad, ADF/KPSS, transformaciones y diferenciación.