
Módulo 4

Dependencia temporal y diagnóstico de series

Análisis y Pronóstico de Datos Mineros con Python

Apuntes + notebook de Google Colab

Objetivo del módulo

dependencia temporal → estacionariedad → diagnóstico → transformación → serie preparada

¿La serie que tengo puede modelarse directamente o debo transformarla primero?

El producto del módulo es una **decisión documentada**: transformación
 $+ d + D + m$.

$$\rho_k = \text{Corr}(X_t, X_{t-k})$$

autocorrelación = cuánto se parece la serie a su propio pasado

El conjunto $\rho_1, \rho_2, \rho_3, \dots$ forma la **ACF** (Función de Autocorrelación). Ejemplo:
 $\rho_1 = 0.85, \rho_2 = 0.72, \rho_3 = 0.58 \Rightarrow$ dependencia que decae.

ACF: interpretación

```
from statsmodels.graphics.tsaplots import plot_acf  
plot_acf(df["Tonelaje"].dropna(), lags=40)
```

- barras dentro de las bandas $\rightarrow$ compatible con cero;
- barras fuera $\rightarrow$ autocorrelación distinta de cero en ese rezago;
- importa el **patrón general**, no cada barra;
- ruido blanco: $\rho_k \approx 0$ para $k > 0$ (ideal para *residuos*);
- picos en $k = 24, 48, 72 \rightarrow$ estacionalidad diaria.

Autocorrelación parcial (PACF)

¿La relación $X_t \leftrightarrow X_{t-2}$ es directa, o pasa por X_{t-1} ?

La PACF mide la relación con X_{t-k} **descontando** los rezagos intermedios: *¿cuánta información nueva aporta ese rezago?*

```
from statsmodels.graphics.tsaplots import plot_pacf
plot_pacf(df["Tonelaje"].dropna(), lags=40)
```

ACF: relaciones directas e indirectas. PACF: aísla la directa.

Estacionariedad (débil)

Queremos que la estructura estadística sea estable:

$$E[X_t] = \mu, \quad \text{Var}(X_t) = \sigma^2, \quad \text{Cov}(X_t, X_{t-k}) \text{ depende de } k, \text{ no de } t$$

estacionariedad = variabilidad estadísticamente estable, NO ausencia de fluctuaciones

Una serie puede fluctuar mucho alrededor de una media constante y ser estacionaria.

No estacionariedad: dos formas

Por la media

$X_t = 100 + 2t + \varepsilon_t$: $E[X_t]$ cambia con el tiempo.

Herramienta:

diferenciación

Por la varianza

$100 \pm 2 \rightarrow 100 \pm 5 \rightarrow 100 \pm 20$: $\text{Var}(X_t)$ crece.

Herramienta:

log / Box-Cox

Media y varianza son problemas **distintos**; podemos necesitar una o ambas.

Pruebas ADF y KPSS

```
from statsmodels.tsa.stattools import adfuller, kpss
adfuller(serie.dropna())[1]          # p-value ADF
kpss(serie.dropna(), regression="c")[1]  # p-value KPSS
```

ADF H_0 : raíz unitaria (no estacionaria). p pequeño $\rightarrow$ estacionaria.

KPSS H_0 : estacionaria. p pequeño $\rightarrow$ no estacionaria.

Ojo: las reglas mentales de ADF y KPSS son **opuestas**.

Combinar la evidencia

ADF	KPSS	Interpretación inicial
rechaza H_0	no rechaza	consistente con estacionariedad
no rechaza	rechaza H_0	consistente con no estacionariedad
no rechaza	no rechaza	ambiguo
rechaza H_0	rechaza H_0	estructura más compleja

Ninguna prueba reemplaza el gráfico, las estadísticas móviles y la ACF.

Diferenciación regular y estacional

$$\Delta X_t = X_t - X_{t-1} \text{ (orden } d) \qquad X_t - X_{t-m} \text{ (orden } D, \text{ periodo } m)$$

```
serie.diff()          # d = 1  
serie.diff(24)        # D = 1, m = 24
```

usar el mínimo grado de diferenciación necesario

Sobrediferenciar convierte señal en ruido y complica el modelo.

$$Y_t = \log X_t \quad Y(\lambda) = \frac{X^\lambda - 1}{\lambda} \text{ (Box-Cox; } \lambda = 0 \Rightarrow \log)$$

```
serie_log = np.log(serie)           # requiere  $X_t > 0$   
from scipy.stats import boxcox  
serie_bc, lam = boxcox(serie.dropna())
```

El log trabaja con cambios *relativos*: $\log(110) - \log(100) \approx \log(1100) - \log(1000)$.

$X_t \rightarrow \log X_t \rightarrow \Delta \rightarrow \Delta_{24} \rightarrow \text{re-evaluar estacionariedad}$

Tendencia / Estacionalidad (m)	...
Varianza estable	Sí / No
ACF persistente	Sí / No
ADF	$p = \dots$
Transformación	ninguna / log / otra
d, D, m	...

Errores conceptuales frecuentes

- creer que "se ve plana" $\Rightarrow$ estacionaria (o "fluctúa mucho" $\Rightarrow$ no);
- confundir autocorrelación alta *por tendencia* con dinámica AR útil;
- diferenciar hasta que "el gráfico parezca ruido";
- aplicar `log`, `diff`, `diff(24)` automáticamente a cualquier serie.

observar $\rightarrow$ diagnosticar $\rightarrow$ transformar $\rightarrow$ volver a diagnosticar

Qué deberías recordar

1. Una serie puede depender de sus valores anteriores.
2. ACF: correlación con rezagos. PACF: relación directa con cada rezago.
3. Estacionariedad = estabilidad de la estructura, no ausencia de fluctuación.
4. ADF y KPSS son complementarias y con reglas opuestas.
5. Tendencia → diferenciación regular.
6. Estacionalidad → diferenciación estacional.
7. Varianza dependiente del nivel → log / Box-Cox.
8. Después de transformar, **siempre** volver a diagnosticar.

Al terminar M4 tenemos, por ejemplo:

$$\log(X_t), \quad d = 1, \quad D = 1, \quad m = 24$$

M4: *¿la serie está preparada para modelarse?*

→ M5: *¿cómo usamos su dependencia temporal para construir un modelo?*

AR → MA → ARMA → ARIMA → SARIMA.