
Módulo 5

Modelamiento de series temporales

Análisis y Pronóstico de Datos Mineros con Python

Apuntes + notebook de Google Colab

Objetivo del módulo

$AR \rightarrow MA \rightarrow ARMA \rightarrow ARIMA \rightarrow SARIMA \rightarrow$ selección $\rightarrow$ ajuste $\rightarrow$ residuos

usar la estructura del pasado para representar el comportamiento presente de la serie

$$X_t = \hat{X}_t + \varepsilon_t \quad (\text{estructura predecible} + \text{componente impredecible})$$

$$AR(1) : \quad X_t = c + \phi_1 X_{t-1} + \varepsilon_t \qquad AR(p) : \quad X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t$$

ϕ_1 mide la **persistencia**:

- $\phi_1 \approx 0$: el valor anterior aporta poco;
- ϕ_1 alto (0.9): fuerte inercia, una perturbación tarda en desaparecer;
- $\phi_1 < 0$: comportamiento alternante.

p = cuántos valores pasados de la serie participan. La **PACF** ayuda a proponerlo.

$$MA(1) : X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} \quad MA(q) : X_t = \mu + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Ojo: no es la media móvil de `rolling().mean()`. El valor actual depende de **errores** pasados: el sistema conserva el efecto de *shocks* recientes. La **ACF** ayuda a proponer q .

$$ARMA(p, q) : \quad X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

ARMA requiere una serie **aproximadamente estacionaria** (por eso el Módulo 4).

$$\boxed{ARIMA(p, d, q)}$$

I = diferenciación para lograr estacionariedad

$ARIMA(p, 0, q) \equiv ARMA(p, q)$. El d viene del diagnóstico de M4, no se elige al azar.

Identificación con ACF/PACF (casos ideales)

	ACF	PACF
AR(p) puro	decae gradualmente	corta cerca de p
MA(q) puro	corta cerca de q	decae gradualmente

Ojo: en datos reales los patrones rara vez son perfectos. ACF/PACF generan *candidatos*, no una regla mecánica.

Selección: ajuste vs. complejidad

AIC = penalización por mal ajuste + penalización por complejidad

BIC: misma lógica, penaliza más la complejidad. *Menor* suele ser preferible **entre modelos comparables**.

Ojo: AIC/BIC **no** miden capacidad predictiva fuera de muestra. Eso se evalúa en M6.

M5: AIC/BIC preseleccionan → M6: desempeño fuera de muestra decide

```
from statsmodels.tsa.arima.model import ARIMA
r = ARIMA(serie, order=(1,1,1)).fit()
print(r.summary())           # coeficientes, AIC, BIC, ...

from statsmodels.tsa.statespace.sarimax import SARIMAX
s = SARIMAX(serie, order=(1,1,1), seasonal_order=(1,1,0,24)).fit()
```

Nos concentramos en: parámetros, AIC/BIC y **residuos**. Un $\hat{\phi}_1 = 0.78$ se interpreta como persistencia temporal, no causalidad.

Residuos: la verdadera prueba

$$e_t = X_t - \hat{X}_t$$

Si el modelo capturó la estructura sistemática, e_t se comporta como **ruido**: media ≈ 0 , sin patrón temporal, sin autocorrelación importante, varianza estable.

```
res = r.resid  
plot_acf(res.dropna(), lags=40)  
r.plot_diagnostics(figsize=(10,8))
```

estructura en residuos = estructura faltante en el modelo

H_0 : no hay autocorrelación conjunta hasta ciertos rezagos

```
from statsmodels.stats.diagnostic import acorr_ljungbox  
acorr_ljungbox(res.dropna(), lags=[10, 20], return_df=True)
```

Queremos $p > 0.05$ (residuos compatibles con ausencia de dependencia). Si $p < 0.05$: queda estructura $\rightarrow$ revisar p , q , d , estacionalidad, transformación.

$$SARIMA(p, d, q)(P, D, Q)_m$$

(p, d, q)	componente no estacional
(P, D, Q)	componente estacional (AR, diferenciación, MA)
m	observaciones por ciclo estacional

Ej.: horario con ciclo diario $\Rightarrow SARIMA(1, 1, 1)(1, 1, 0)_{24}$. SARIMAX en Python permite además variables exógenas (la "X").

```
from pmdarima import auto_arima  
modelo = auto_arima(serie, seasonal=True, m=24, trace=True)
```

Es una **búsqueda automática** entre modelos estadísticos comparando criterios. No es inteligencia artificial.

automatización $\neq$ criterio

Sigue siendo necesario preparar datos, verificar estacionalidad, revisar residuos y validar el forecast.

- `modelo.fit()` $\Rightarrow$ "modelo terminado" (falta revisar residuos);
- elegir por R^2 ;
- "modelo más complejo = mejor";
- probar $ARIMA(1, 1, 1), (2, 1, 1), (3, 1, 1), \dots$ sin criterio;
- creer que auto-ARIMA "decide por mí".

Qué deberías recordar

1. AR usa valores pasados; MA usa errores pasados; ARMA combina.
2. ARIMA agrega diferenciación: p rezagos AR, d diferencias, q rezagos MA.
3. SARIMA incorpora estructura estacional $(P, D, Q)_m$.
4. ACF/PACF generan candidatos, no deciden.
5. AIC/BIC comparan ajuste y complejidad (no predicción).
6. Auto-ARIMA automatiza la búsqueda, no el análisis.
7. Siempre revisar residuos (ruido blanco) y Ljung–Box ($p > 0.05$).
8. Buen ajuste $\neq$ buen pronóstico.

Resultado del M5 (prudente):

tenemos uno o varios modelos estadísticamente razonables

→ Módulo 6: *¿qué ocurre cuando intentamos predecir datos que el modelo nunca vio?*

Train/test cronológico, horizonte, intervalos, MAE/RMSE/MAPE, naïve, backtesting.