
Módulo 6

Pronóstico y evaluación de modelos

Análisis y Pronóstico de Datos Mineros con Python

Apuntes + notebook de Google Colab

Objetivo del módulo

horizonte → train/test temporal → forecast → incertidumbre → métricas → baseline → backtesting

¿El modelo que construimos realmente predice bien datos futuros?

Un modelo puede describir muy bien el pasado y fallar al pronosticar.

La regla temporal fundamental

$$\underbrace{X_1, \dots, X_{900}}_{\text{train (pasado)}} \quad \underbrace{X_{901}, \dots, X_{1000}}_{\text{test (futuro no visto)}}$$

Ojo: nada de `train_test_split` aleatorio. Entrenar con diciembre y evaluar en octubre es usar el futuro para predecir el pasado.

```
n_train = int(len(serie) * 0.8)
train, test = serie.iloc[:n_train], serie.iloc[n_train:]
```

Horizonte de pronóstico

h = cuántos periodos hacia adelante. Datos horarios: $h = 8$ (turno), $h = 168$ (semana).

el error suele crecer con el horizonte

$\hat{X}_{t+1}$ es más fácil que $\hat{X}_{t+100}$: las predicciones lejanas dependen cada vez más de información estimada. La pregunta correcta: *¿cuánto adelante necesita realmente la operación?*

Predicción puntual e intervalo

```
| pred = resultado.get_forecast(steps=len(test))  
| fc = pred.predicted_mean           # predicción puntual  
| ci = pred.conf_int()              # banda del pronóstico
```

$\hat{X}_{t+1} = 1500$ con intervalo $[1450, 1550]$ dice mucho más que solo "1500".

IC vs IP: el intervalo de confianza es para un parámetro / valor medio; el *intervalo de predicción* es para una observación futura (más ancho). La banda se ensancha con h .

$$MAE = \frac{1}{n} \sum |y_t - \hat{y}_t| \quad RMSE = \sqrt{\frac{1}{n} \sum (y_t - \hat{y}_t)^2}$$

$$MAPE = \frac{100}{n} \sum \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

- MAE: magnitud media, misma unidad, muy interpretable;
- RMSE: penaliza más los errores grandes ($RMSE \gg MAE \Rightarrow$ hay fallas grandes);
- MAPE: porcentual, pero **explota** cuando $y_t \approx 0$ (detenciones, producción baja).

$$\hat{X}_{t+1} = X_t \quad \text{o estacional} \quad \hat{X}_t = X_{t-m}$$

```
naive      = pd.Series(train.iloc[-1], index=test.index)
naive_est  = serie.shift(24)
```

un modelo complejo debe superar una referencia simple

Si el ARIMA no supera al naïve: el problema es difícil, el modelo está mal especificado, o la persistencia domina.

Una sola partición puede engañar (¿ese 20 % final fue fácil o difícil?).

```
historia = list(train); predicciones = []  
for observado in test:  
    ajuste = ARIMA(historia, order=(2,1,1)).fit()  
    predicciones.append(ajuste.forecast(1)[0])  
    historia.append(observado)
```

Ventana expansiva: el train crece. **Ventana deslizante:** tamaño fijo, útil si el proceso cambia de régimen.

Qué entrega el backtesting

Errores en múltiples momentos $e_1, e_2, \dots, e_n$: error medio, dispersión, peores casos, error por periodo, estabilidad temporal del desempeño.

Horizonte	MAE
1 h	25
8 h	65
24 h	130

¿Hasta qué horizonte el pronóstico sigue siendo operacionalmente útil?

$$ME = \frac{1}{n} \sum (y_t - \hat{y}_t)$$

$ME > 0$: el modelo subestima. $ME < 0$: sobrestima. Un MAE pequeño puede ocultar un sesgo sistemático (p. ej. subestimar 5 % la demanda energética → falta de capacidad).

no basta con medir cuánto falla; importa cómo falla

M5: AIC/BIC preseleccionan → M6: backtesting decide

No siempre el menor error: también estabilidad, complejidad, costo, actualización, interpretabilidad y magnitud *real* de la mejora.

mejora estadística del forecast $\neq$ mejora operacional relevante

Bajar MAE de 100 a 20 cambia una decisión; de 50.1 a 49.9, probablemente no.

Qué deberías recordar

1. Buen ajuste $\neq$ buen pronóstico.
2. El test representa futuro no observado: nada de mezcla aleatoria.
3. El horizonte importa ($h = 1 \neq h = 24$).
4. La predicción puntual va con incertidumbre.
5. MAE (magnitud), RMSE (penaliza grandes), MAPE (porcentual, falla cerca de 0).
6. Toda predicción se compara contra un baseline naïve.
7. Una sola partición engaña $\rightarrow$ backtesting / walk-forward.
8. AIC/BIC no deciden; decide el desempeño fuera de muestra.
9. El mejor modelo no siempre es el más complejo.

serie → modelo → pronóstico → evaluación

Tenemos evidencia de cuánto se equivoca, a qué horizonte, con qué incertidumbre y si supera una referencia trivial.

→ Módulo 7: *¿y si el modelo no se equivocó, sino que el proceso empezó a comportarse de forma anormal?*