
Módulo 7

Detección de anomalías y cambios en el proceso

Análisis y Pronóstico de Datos Mineros con Python

Apuntes + notebook de Google Colab

Objetivo del módulo

anomalía puntual → métodos robustos → límites dinámicos → residuos → cambio persistente → régimen

¿Cómo detectamos que un proceso empieza a comportarse de forma distinta a la esperada?

Pico aislado $\neq$ cambio persistente

100, 102, 101, 99, 103, **170**, 101, 100 $\Rightarrow$ anomalía puntual

100, 101, 99, 102, 100, **130, 131, 129, 132, 130, ...** $\Rightarrow$ nuevo nivel $\mu_1 \rightarrow \mu_2$

pico aislado $\neq$ nuevo comportamiento del proceso

Python detecta "estadísticamente inusual"; la causa (falla, cambio de mineral, mantenimiento) requiere contexto operacional.

Z-score y su problema

$$z_i = \frac{x_i - \bar{x}}{s}, \quad \text{sospechoso si } |z| > 3$$

```
z = (serie - serie.mean()) / serie.std()  
anomalias = serie[z.abs() > 3]
```

Ojo: $\bar{x}$ y s son sensibles justo a los extremos que queremos detectar.

10, 10, 11, 9, 10, **1000**: el propio outlier infla media y desviación.

Métodos robustos: mediana y MAD

$$MAD = \text{median} (|X_i - \text{median}(X)|)$$

```
med = serie.median()  
mad = (serie - med).abs().median()  
z_rob = 0.6745 * (serie - med) / mad
```

media / std → sensibles mediana / MAD / IQR → robustos

El nivel "normal" cambia con el tiempo; un límite fijo $\bar{x} \pm 3s$ deja de servir.

$$L_t^{\text{sup}/\text{inf}} = \mu_t^{(w)} \pm k \sigma_t^{(w)}$$

```
mu = serie.rolling(w, center=True).mean()  
sg = serie.rolling(w, center=True).std()  
fuera = serie[(serie > mu + 3*sg) | (serie < mu - 3*sg)]
```

una anomalía depende del contexto esperado

Ventana corta: se adapta incluso a la anomalía. Larga: reacciona tarde.

Filtro de Hampel

Ventana móvil + estadística robusta: para cada t se usa la **mediana** y el **MAD** *locales*.

Hampel = detector robusto y local

Adecuado para picos aislados en series cuyo nivel se desplaza (una tendencia no lo "engaña").

Residuos del modelo como detector

$$e_t = X_t - \hat{X}_t$$

Con estacionalidad diaria, $X_t = 200$ puede ser normal si $\hat{X}_t = 195$ ($e_t = 5$), pero anómalo si $\hat{X}_t = 120$ ($e_t = 80$).

anomalía = observación incompatible con lo que el modelo esperaba

```
e = observado - predicho
fuera = e[(e > e.mean() + 3*e.std()) | (e < e.mean() - 3*e.std())]
# o: observado fuera del intervalo de predicción [L_t, U_t]
```


Nivel	Tendencia	Variabilidad
$\mu_1 \neq \mu_2$ (setpoint, alimentación)	$\beta_1 \neq \beta_2$ (desgaste, deriva de sensor)	$\sigma_1^2 \neq \sigma_2^2$ (proceso menos estable)

Régimen: estado con comportamiento estadístico estable.

$A(\mu = 100, \sigma = 5) \rightarrow B(\mu = 130, \sigma = 10)$: cambia la distribución y la dinámica. Un ARIMA entrenado en A verá crecer sus residuos en B.

CUSUM: cambios pequeños pero persistentes

$$S_t = S_{t-1} + e_t$$

Errores alrededor de cero: la suma no crece. Sesgo sistemático (+3, +4, +2, +5, ...): la suma aumenta sostenidamente.

detección puntual $\neq$ detección de cambio persistente

$|e_t| > 3\sigma$ ve eventos grandes; no ve $e_t = 1.2\sigma$ repetido muchas veces.

Change-point detection

Buscar τ tal que $X_{t < \tau}$ y $X_{t \geq \tau}$ tienen comportamiento estadístico distinto.

```
import ruptures as rpt  
bkps = rpt.Pelt(model="rbf").fit(y).predict(pen=15)
```

El algoritmo entrega **una señal**; el experto entrega **una interpretación**: revisar logs, setpoints, mantenimiento, cambios de turno o de material.

Sensibilidad vs. falsas alarmas

sensibilidad $\leftrightarrow$ falsas alarmas

Umbral $\pm 1\sigma$: muchas alertas, casi todas ruido $\rightarrow$ el personal las ignora. Umbral $\pm 5\sigma$: pocas falsas alarmas, pero se pierden eventos.

Dos errores operacionales: **falsa alarma** (dice "problema" y no lo hay) y **evento no detectado**. El umbral debe responder al *costo de equivocarse*.

Qué deberías recordar

1. Un atípico no es necesariamente un error.
2. Pico $\neq$ nuevo régimen.
3. Z-score es simple; media/std son sensibles a outliers.
4. Alternativas robustas: mediana, MAD, IQR.
5. El comportamiento esperado cambia $\rightarrow$ límites dinámicos.
6. El modelo de pronóstico sirve para vigilar: $e_t = X_t - \hat{X}_t$.
7. Residuo grande = comportamiento inesperado, no falla confirmada.
8. Cambios en nivel, tendencia o variabilidad.
9. Una secuencia de errores pequeños puede pesar más que uno grande (CUSUM).
10. Toda detección automática requiere validación operacional.

observado — esperado → desviación → alerta → interpretación

El modelo ya no solo responde *¿qué ocurrirá?* sino también *¿está ocurriendo algo distinto de lo que debería?*

→ Módulo 8: un caso minero completo, de los datos brutos a una decisión.